Описание на уровне транзакций позволяет существенно ускорить как время симуляции, так и простоту описания работы модуля, давая возможность описывать работу используя стандартные и сторонние C++ библиотеки [5].

Разработанная модель позволяет верифицировать не только отдельные модули, но и крупные системы. Также, используя уже реализованные модули BFM, имеется возможность внедрять в потактовую SystemVerilog модель SystemC блоки, работающие на уровне транзакций, что дает возможность заменять в тестируемой системе определенные, например, еще не написанные, модули. Таким образом, написанная на SystemC транзакционная модель позволяет верифицировать всю систему целиком на любом этапе разработки.

Литература

1. The power of virtual prototyping: From SoC design to software development // Semiconductor engineering: [Электронный портал]. URL: https://semiengineering.com/the-power-of-virtual-prototyping-from-soc-design-to-software-development/ (дата обращения: 25.02.2025).
2. *Kogel T.* Virtual Prototyping of Processor-Based Platforms // Handbook of Computer Architecture. — Singapore: Springer, 2025. P. 947–987. DOI: 10.1007/978-981-97-9314-3_44.
3. *Wicaksana A., Tang C. M.* Virtual Prototyping Platform for Multiprocessor System-on-Chip Hardware/Software Co-design and Co-verification // Computer and Information Science. — Cham: Springer, 2018. (Studies in Computational Intelligence, V. 719). P. 93–108. DOI: 10.1007/978-3-319-60170-0_7.
4. *Kabir M. R., Ray S.* Virtual Prototyping for Modern Internet-of-Things Applications: A Survey // IEEE Access. 2023. V. 11. P. 31384–31398. DOI: 10.1109/ACCESS.2023.3262499.
5. IEEE Standard for Standard SystemC Language Reference Manual // IEEE Standards Association : [Электронный портал]. URL: https://standards.ieee.org/ieee/1666/7293/ (дата обращения: 25.02.2025).

УДК 004.896

Исследование применимости сверточных и физически обоснованных нейронных сетей для моделирования процесса экспонирования в ILT

***Я. Д. Николаев*[1,2], *А. В. Кошлаков*[1,2], *И. Ю. Федоров*[2], *А. А. Метельников*[2]**

[1]Московский физико-технический институт (национальный исследовательский университет)
[2]ПАО «Сбербанк»

Процесс изготовления слоя микроэлектронного компонента методом оптической литографии подвержен влиянию искажений, вносимых оптической системой (ОС) [1] и фоторезистом [2]. Эти искажения приводят к размытию формы топологического элемента и отличию ее от разработанного чертежа. Использование методов инверсной вычислительной литографии (ILT — Inverse Lithography Technology) [3] и алгоритмов коррекции оптической близости (OPC — Optical Proximity Correction) [4] позволяет уменьшить и/или скомпенсировать данные нежелательные эффекты, но требует наличия точных и быстрых симуляторов процесса экспонирования [5]. В этих условиях перспективной является разработка методов симуляции процесса печати с использованием современных подходов на основе глубокого обучения (DL) [3]. Алгоритмы, такие как LithoGan [6] и DAMO [7], положили начало развитию направления применения сверточных нейронных сетей в данной области, использующих в качестве входных данных исходный чертеж фотошаблона, а в качестве результата — бинаризованное изображение на фоторезисте [8]. Однако из-за сложности получения данных и/или их недостаточности, полученный результат часто не позволяет смоделировать все разнообразие топологических структур [9]. Дальнейшее развитие нейросетевых методов в таких случаях осуществляется благодаря использованию PINN (Physics-Informed Neural Networks) [10], основанных на физических правилах, и, в частности, за счет применения нейронных операторов Фурье (FNO — Fourier Neural Operator) [11].

В данной работе рассматриваются вопросы симуляции литографического процесса путем использования как классического дифракционно-ограниченного симулятора Хопкинса [12, 13] и компактной модели резиста, так и посредством нейросетевых алгоритмов. Исследуемые в работе нейросетевые архитектуры включают DeepLabV3 [14], UNet [15], Doinn [11] и Nitho [10]. Построение нейросетевого симулятора было разделено на две подзадачи: end-to-end и частичная симуляции. End-to-end решение подразумевает симуляцию резиста исключительно на основе маски, тогда как частичная симуляция основана на воздушном изображении. Для задачи end-to-end симуляции применяется комбинация архитектур:

Nitho генерирует воздушное изображение из маски, а Doinn проводит последующую симуляцию резиста. Рассматриваемые методы были протестированы на широко известных синтетических данных манхэттенских структур [16].

В ходе исследования было выявлено, что сверточные нейронные сети (UNet и DeepLabV3) имеют общий недостаток — появление пустот внутри топологии выходных структур. Кроме того, UNet урезает границы самих структур. Архитектура Doinn хорошо справляется с симуляцией внутренних структур, однако иногда искажает границы мелких топологических объектов, уменьшая их размеры. В итоге лучшим вариантов для полной симуляции было выбрано сочетание Nitho (для симуляции воздушного изображения по маске) и Doinn (для дальнейшей симуляции резиста по предсказанному воздушному изображению). Для частичной симуляции наиболее подходящей архитектурой является Doinn.

Появление незаполненных областей внутри структур — это критический недостаток, существенно ограничивающий возможность использования модели без дополнительной постобработки в качестве симулятора в задаче ILT. После такой симуляции у структуры появляется дополнительная внутренняя граница, которой изначально не должно было быть. Общепринятые метрики, такие как IoU и Dice, недостаточно чувствительны к выявлению данной аномалии. Поэтому в работе была предложена собственная топологическая метрика для обнаружения этих областей в симулированных структурах, основанная на эйлеровой характеристике [17] и изменении количества компонентов связности:

$$TopoMetric = (1 - \frac{|C-C'| + |H-H'|}{C+C'+H+H'}) \cdot 100\%, \quad (1)$$

где C — количество компонентов связности на эталонном изображении, C' — количество компонентов связности на предсказанном изображении, H — количество пустот («дырок») на эталонном изображении, H' — количество «дырок» на предсказанном изображении. Количество «дырок» в изображении определяется как разность между количеством компонентов связности и эйлеровой характеристикой.

Дальнейшие исследования направлены на объединение подходов архитектуры DeepLabV3, а именно — использование модуля ASPP (Atrous Spatial Pyramid Pooling) и dilated сверток, что позволяет расширить зону восприимчивости сверточной сети, с методами архитектур Nitho и Doinn, которые предполагают внедрение физических правил в структуру сети. Ожидается, что такая комбинация обеспечит устойчивость к возникновению нежелательных пустот внутри структур, сократит ошибки, связанные с сужением небольших частей топологий, и улучшит показатели как традиционных метрик, так и предложенной топологической метрики TopoMetric.

Литература

1. *Schellenberg F.* A little light magic [optical lithography] // IEEE Spectrum. 2003. V. 40(9). P. 34–39.
2. *Mack C.* Fundamental principles of optical lithography: the science of microfabrication. — New York: Wiley, 2008.
3. *Pang L.* Inverse lithography technology: 30 years from concept to practical, full-chip reality // Journal of Micro/Nanopatterning, Materials, and Metrology. 2021. V. 20(3). P. 030901–030901.
4. *Ma X., Arce G. R.* Computational lithography. — New York: Wiley, 2011.
5. *Gau T. S.* [et al.]. Ultra-fast aerial image simulation algorithm using wavelength scaling and fast Fourier transformation to speed up calculation by more than three orders of magnitude // Journal of Micro/Nanopatterning, Materials, and Metrology. 2023. V. 22(2). P. 023201–023201.
6. *Yang H.* [et al.]. GAN-OPC: Mask optimization with lithography-guided generative adversarial nets // Proceedings of the 55th Annual Design Automation Conference. 2018. P. 1–6.
7. *Chen G.* [et al.]. DAMO: Deep agile mask optimization for full chip scale // Proceedings of the 39th International Conference on Computer-Aided Design. 2020. P. 1–9.
8. *Zhang Y., Ye W.* Deep learning–based inverse method for layout design // Structural and Multidisciplinary Optimization. 2019. V. 60(2). P. 527–536.
9. *Sun C.* [et al.]. Revisiting unreasonable effectiveness of data in deep learning era // Proceedings of the IEEE international conference on computer vision. 2017. P. 843–852.
10. *Chen G.* [et al.]. Physics-informed optical kernel regression using complex-valued neural fields // 2023 60th ACM/IEEE Design Automation Conference (DAC). — IEEE, 2023. P. 1–6.
11. *Yang H.* [et al.]. Generic lithography modeling with dual-band optics-inspired neural networks // Proceedings of the 59th ACM/IEEE Design Automation Conference. — 2022. P. 973–978.
12. *Hopkins H. H.* On the diffraction theory of optical images // Proceedings of the Royal Society of London. Series A. Mathematical and Physical Sciences. 1953. V. 217(1130). P. 408–432.
13. *Flagello D. G., Smith D. G.* Calculation and uses of the lithographic aerial image // Advanced Optical Technologies. 2012. V. 1(4). P. 237–248.
14. *Chen L. C.* [et al.]. Rethinking atrous convolution for semantic image segmentation // arXiv preprint. [2017]. arXiv: 1706.05587.