В рамках работы подготовлена реализация на основе фреймворка компиляции OpenXLA — стандартного механизма, предназначенного для удобной интеграции популярных библиотек машинного обучения с компилятором. Он предоставляет универсальные интерфейсы и инструменты, которые упрощают процесс компиляции и выполнения моделей, гарантируя высокую производительность [2].

Реализация позволяет компилятору определить оптимальную раскладку тензора с учетом таких факторов, как выравнивание данных и порядок расположения осей в памяти, и сообщить ее клиенту, взаимодействующему с библиотекой машинного обучения. В случае, если исходная раскладка, предоставленная библиотекой, не соответствует оптимальной для устройства, клиент преобразует данные, что избавляет от накладных расходов по перераскладке на самом устройстве.

Результаты экспериментов показывают значительное улучшение производительности, что подтверждает эффективность предложенного подхода. Разработанный механизм также позволяет гибко адаптировать оптимизацию под различные типы устройств и фреймворков, обеспечивая универсальность решения.

Литература

1. Outpacing Moore's Law: The AI Performance Surge [Электронный ресурс] URL: https://jon-bown.github.io/blog/ml/2023/06/07/MooresLaw.html (дата обращения: 03.03.25).
2. OpenXLA Project [Электронный ресурс] URL: https://openxla.org (дата обращения: 03.03.25).

УДК 004.896

Метод выбора набора данных для обучения нейронных сетей, основанный на анализе распределения интенсивности оптического излучения на поверхности фоторезиста

***А. В. Кошлаков*[1,2], *Я. Д. Николаев*[1,2], *А. А. Метельников*[2]**

[1]Московский физико-технический институт (национальный исследовательский университет)
[2]ПАО Сбербанк

Сегодня для моделирования процесса формирования контура фоторезистивной маски (ФРМ) используются аппроксимационные модели. Их калибровка сводится к подбору коэффициентов полинома на основе анализа распределения интенсивности оптического излучения, создаваемого в слое фоторезиста (далее «воздушное изображение»), заданного значения постоянного порога и результатов печати на пластине специально подобранных тестовых паттернов. При этом тестовые паттерны выбираются таким образом, чтобы обеспечить максимально возможный охват параметров воздушного изображения [1].

В настоящей работе данный подход применен к выбору набора данных для обучения нейросетевой модели фоторезиста на основе архитектуры DOINN [2]. Произведено его сравнение с алгоритмом, предложенным в работе [3].

Для оценки качества работы нейронной сети использовалась классическая метрика, применимая для задач машинного обучения MSE, а также метрика EPE (Edge Placement Error), которая характеризует ошибку размещения ребер фрагментов в смоделированном контуре. Набор данных для семплирования (DES, Default element set) был собран из изображений простых структур: одиночные линии, параллельные линии, перпендикулярные линии.

Для обучения нейронной сети DOINN были сформированы два набора. Первый (UDES, Uniformly sampled DES) представлял собой равномерное семплирование DES в пространстве геометрических признаков (толщина линии структуры и ширина промежутка между структурами). Для получения второй обучающей выборки (DIF, DES Intensity features) было выполнено семплирование в пространстве характеристик «воздушного изображения».

Таблица 1. Результат обучения нейросетевой модели фоторезиста

Обучающий набор	MSE		EPE		Тестовая выборка
	Mean	Std	Mean	Std	
UDES	0,0007834	0,0006003	0,8949	1,1654	Случайное семплирование DES
DIF (ours)	**0,0005659**	**0,0002884**	**0,7723**	**0,5506**	
UDES	0,0136700	0,0083760	17,9166	10,4974	LAB
DIF (ours)	**0,0125840**	**0,0077935**	**14,7286**	**6,4685**	

Обучающий набор был разбит на тренировочную и тестовую выборки в соотношении 9:1 Помимо тестовой выборки, сформированной из набора DES, с помощью алгоритма генерации лабиринтов из [4] была сформирована тестовая выборка, имитирующая реальный дизайн (LAB). Результаты обучения отражены в табл. 1.

В результате можно сделать вывод, что использование во время формирования обучающего набора данных равномерного семплирования в пространстве характеристик «воздушного изображения», а не пространстве геометрических признаков, позволило улучшить качество предсказания изображения ФРМ нейросетевой моделью фоторезиста по метрике EPE на 14–18 %, по метрике MSE на 8–28 %.

Литература

1. *Балан Н. Н.* [и др.]. Основные подходы к моделированию формирования фоторезистивной маски в вычислительной литографии // Известия высших учебных заведений. Материалы электронной техники. 2019. V. 22(4). P. 279–289. DOI: 10.17073/1609-3577-2019-4-279-289.
2. *Yang H.* [et al.]. Generic lithography modeling with dual-band optics-inspired neural networks // Proceedings of the 59th ACM/IEEE Design Automation Conference, 2022. P. 973–978. DOI: 10.1145/3489517.3530580.
3. *Кошлаков А. В.* [и др.]. Разработка подхода по выбору набора данных для нейросетей, моделирующих процесс экспонирования в фотолитографии, на основе нейроператоров Фурье // Тезисы докладов научной конференции «ЭКБ и микроэлектронные модули». Российский форум «Микроэлектроника 2024». 2024. С. 387–388.
4. Python-maze // GitHub: [Электронная платформа]. URL: https://github.com/guofei9987/python-maze (дата обращения: 25.02.2025).

УДК 004.415

Архитектура сбора телеметрии для модели производительности вычислительной системы

П. И. Крюков[1,2]

[1]Московский физико-технический институт (национальный исследовательский университет)
[2]ПАО «Сбербанк»

Распространенными средствами анализа работы современных программно-аппаратных комплексов являются программные модели производительности, такие как потактовые или событийные симуляторы [1]. Преимуществом таких моделей является легкость добавления и сбора различной телеметрии: как непосредственно производительности, определяемой количеством выполненных за единицу времени задач, так и более специфичных метрик, таких как пропускная способность памяти, распределение выполненных команд по типам, число прерываний и тому подобные величины [2]. Данные, порождаемые в результате моделирования, могут быть получены в разных форматах, после чего обработаны и агрегированы в табличном представлении, в виде графиков либо диаграмм, и применены для принятия решений по оптимизации и развитию программно-аппаратного комплекса.

На успех применения модели производительности влияет наличие у нее свойств масштабируемости, тестируемости, возможности интеграции с другими симуляторами, а также высокой скорости моделирования [3]. Сбалансированное обеспечение этих факторов составляет предмет архитектуры программных продуктов. Одним из основных принципов архитектуры является сокрытие информации в пределах структурных единиц, таких как функции, классы, единицы трансляции, микросервисы [4]. В результате, внедрение телеметрии вступает в техническое противоречие с этим принципом: с одной стороны, для целостного анализа данные должны быть агрегированы со всех блоков симулятора, с другой стороны — структурные зависимости между такими блоками должны быть минимизированы.

Для поддержки различных способов представления данных и решения задачи сокрытия информации нами предлагается архитектура из трех компонент. В первую очередь, это вызовы универсальных интерфейсов сбора, встраиваемые в каждый измеримый узел модели (модуль). Далее, это набор классов, собирающих данные с каждого модуля и реализующих их определенное представление. Наконец, это связующее звено, отвечающее за инициализацию остальных узлов посредством фабрики и передачу данных между остальным узлами.

Обеспечение сокрытия информации требует внедрения ациклических зависимостей между узлами: добавление новых интерфейсов сбора в модули не должно влиять на сборку баз данных и средств представлений, а модификация и/или увеличение количества последних — на модуль. Для этого нами предла-